Veri Analizi Dönem Projesi

2023-06-16

```
library(readxl)
library(psych)
library(dplyr)
```

```
##
## Attaching package: 'dplyr'
```

```
## The following objects are masked from 'package:stats':
##
##     filter, lag
```

```
## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union
```

```
library(ggplot2)
```

```
##
## Attaching package: 'ggplot2'
```

```
## The following objects are masked from 'package:psych':
##
##     %+%, alpha
```

```
library(rcompanion)
```

```
##
## Attaching package: 'rcompanion'
```

```
## The following object is masked from 'package:psych':
##
##     phi
```

```
library(car)
```

```
## Zorunlu paket yükleniyor: carData
```

```
##
## Attaching package: 'car'
```

```
## The following object is masked from 'package:dplyr':
##
##     recode
```

```
## The following object is masked from 'package:psych':
##
##     logit
```

```
library(MASS)
```

```
##
## Attaching package: 'MASS'
```

```
## The following object is masked from 'package:dplyr':
##
##     select
```

```
library(readxl)
orneklem <- read_excel("C:/Users/ayses/Desktop/orneklem.xlsx")
View(orneklem)
```

Veri setinin özetini görelim.

```
summary(orneklem)
```

```
##    RowNumber      CustomerId         Surname           CreditScore   
##  Min.   :  39   Min.   :15565806   Length:1000        Min.   :363.0  
##  1st Qu.:2380   1st Qu.:15630230   Class :character   1st Qu.:582.0  
##  Median :4993   Median :15696010   Mode  :character   Median :651.0  
##  Mean   :5017   Mean   :15693355                      Mean   :647.3  
##  3rd Qu.:7634   3rd Qu.:15755843                      3rd Qu.:711.2  
##  Max.   :9998   Max.   :15815125                      Max.   :850.0  
##   Geography            Gender               Age            Tenure      
##  Length:1000        Length:1000        Min.   :18.00   Min.   : 0.000  
##  Class :character   Class :character   1st Qu.:32.00   1st Qu.: 3.000  
##  Mode  :character   Mode  :character   Median :37.00   Median : 5.000  
##                                        Mean   :38.87   Mean   : 5.165  
##                                        3rd Qu.:44.00   3rd Qu.: 8.000  
##                                        Max.   :83.00   Max.   :10.000  
##    Balance          NumOfProducts     HasCrCard     IsActiveMember 
##  Length:1000        Min.   :1.000   Min.   :0.000   Min.   :0.000  
##  Class :character   1st Qu.:1.000   1st Qu.:0.000   1st Qu.:0.000  
##  Mode  :character   Median :1.000   Median :1.000   Median :1.000  
##                     Mean   :1.527   Mean   :0.718   Mean   :0.508  
##                     3rd Qu.:2.000   3rd Qu.:1.000   3rd Qu.:1.000  
##                     Max.   :4.000   Max.   :1.000   Max.   :1.000  
##  EstimatedSalary        Exited     
##  Length:1000        Min.   :0.000  
##  Class :character   1st Qu.:0.000  
##  Mode  :character   Median :0.000  
##                     Mean   :0.208  
##                     3rd Qu.:0.000  
##                     Max.   :1.000  
```

Eksik Veri İncelemesi

```
# Eksik verileri yazdırma
eksik_veriler <- orneklem[is.na(orneklem)]
print(eksik_veriler)
```

```
## <unspecified> [0]
```

Veri setinde eksik değer bulunmamaktadır.

Not: Uygulama amaçlı yapılan eksik değer oluşturma işlemi knit işleminde hataya sebebiyet verdiğinden orneklem_cekme html dosyasında yapılmıştır.

Verideki Kategorik Değişkenleri Faktöre Çevirme

```
# Gender sütununu güncelle
orneklem$Gender <- ifelse(orneklem$Gender == "Female", 1, 0)
```

Unique değerlei veri kümemizden atalım.

```
orneklem <- orneklem[, !(names(orneklem) %in% c("RowNumber", "CustomerId", "Surname", "Geography"))]
```

Örneklemi test ve train olmak üzere ayıralım.

```
set.seed(8367325)
trainIndex <- sample(1:nrow(orneklem), size = round(0.8*nrow(orneklem)), replace=FALSE)
train <- orneklem[trainIndex ,]
test <- orneklem[-trainIndex ,]
```

```
#Export data from R to Excel
library("openxlsx")
write.xlsx(train, 'train.xlsx')
write.xlsx(test, 'test.xlsx')
```

###Kategorik degiskenler icin factor tanimlama:

```
train$Gender <- as.factor(train$Gender)

glimpse(train)
```

```
## Rows: 800
## Columns: 10
## $ CreditScore     <dbl> 692, 466, 643, 849, 683, 551, 714, 682, 683, 681, 655,…
## $ Gender          <fct> 0, 0, 0, 1, 1, 1, 0, 1, 0, 1, 1, 0, 1, 1, 0, 0, 0, 0, …
## $ Age             <dbl> 24, 40, 33, 41, 29, 30, 28, 33, 35, 18, 36, 44, 47, 48…
## $ Tenure          <dbl> 2, 4, 4, 9, 0, 2, 6, 8, 9, 1, 10, 7, 8, 7, 8, 2, 5, 3,…
## $ Balance         <chr> "120596.93", "91592.06", "0", "115465.28", "157829.12"…
## $ NumOfProducts   <dbl> 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 2, 1, 2, 2, 1, 2, 2, …
## $ HasCrCard       <dbl> 0, 1, 1, 1, 0, 1, 1, 1, 0, 1, 1, 1, 1, 1, 1, 1, 0, 1, …
## $ IsActiveMember  <dbl> 1, 0, 1, 0, 0, 0, 1, 1, 0, 1, 0, 1, 0, 0, 0, 1, 0, 1, …
## $ EstimatedSalary <chr> "180490.53", "141210.18", "152992.04", "103174.5", "12…
## $ Exited          <dbl> 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, …
```

```
rowSums(is.na(train))
```

```
##   [1] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
##  [38] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
##  [75] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [112] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [149] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [186] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [223] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [260] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [297] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [334] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [371] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [408] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [445] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [482] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [519] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [556] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [593] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [630] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [667] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [704] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [741] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
## [778] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
```

```
colSums(is.na(train))
```

```
##     CreditScore          Gender             Age          Tenure         Balance 
##               0               0               0               0               0 
##   NumOfProducts       HasCrCard  IsActiveMember EstimatedSalary          Exited 
##               0               0               0               0               0 
```

```
train$Age <- as.numeric(as.character(train$Age))

train$Yas_kat <- ifelse(train$Age <= 25, "Genc",
                  ifelse(train$Age >= 26 & train$Age <= 45, "Orta_yasli",
                   ifelse(train$Age >= 46 & train$Age <= 65, "Yasli", "Ileri_yasli")))
```

```
#turetilen kategorik degiskeni tekrar factor olarak tanimlamak gerekli

train$Yas_kat <- factor(train$Yas_kat, levels=c("Genc","Orta_yasli","Yasli","Ileri_yasli"))
summary(train)
```

```
##   CreditScore    Gender      Age            Tenure          Balance         
##  Min.   :414.0   0:446   Min.   :18.00   Min.   : 0.000   Length:800        
##  1st Qu.:582.0   1:354   1st Qu.:33.00   1st Qu.: 3.000   Class :character  
##  Median :655.0           Median :38.00   Median : 5.000   Mode  :character  
##  Mean   :649.3           Mean   :39.22   Mean   : 5.189                     
##  3rd Qu.:714.0           3rd Qu.:44.00   3rd Qu.: 8.000                     
##  Max.   :850.0           Max.   :83.00   Max.   :10.000                     
##  NumOfProducts     HasCrCard      IsActiveMember   EstimatedSalary   
##  Min.   :1.000   Min.   :0.0000   Min.   :0.0000   Length:800        
##  1st Qu.:1.000   1st Qu.:0.0000   1st Qu.:0.0000   Class :character  
##  Median :1.000   Median :1.0000   Median :1.0000   Mode  :character  
##  Mean   :1.525   Mean   :0.7238   Mean   :0.5112                     
##  3rd Qu.:2.000   3rd Qu.:1.0000   3rd Qu.:1.0000                     
##  Max.   :4.000   Max.   :1.0000   Max.   :1.0000                     
##      Exited              Yas_kat   
##  Min.   :0.0000   Genc       : 43  
##  1st Qu.:0.0000   Orta_yasli :585  
##  Median :0.0000   Yasli      :158  
##  Mean   :0.2087   Ileri_yasli: 14  
##  3rd Qu.:0.0000                    
##  Max.   :1.0000                    
```

###Degisken tiplerine gore incelemeler:

```
library(funModeling)
```

```
## Zorunlu paket yükleniyor: Hmisc
```

```
##
## Attaching package: 'Hmisc'
```

```
## The following objects are masked from 'package:dplyr':
##
##     src, summarize
```

```
## The following object is masked from 'package:psych':
##
##     describe
```

```
## The following objects are masked from 'package:base':
##
##     format.pval, units
```

```
## funModeling v.1.9.4 :)
## Examples and tutorials at livebook.datascienceheroes.com
##  / Now in Spanish: librovivodecienciadedatos.ai
```

```
#niceller
plot_num(train)
```

```
## Warning: The `<scale>` argument of `guides()` cannot be `FALSE`. Use "none" instead as
## of ggplot2 3.3.4.
## ℹ The deprecated feature was likely used in the funModeling package.
##   Please report the issue at <https://github.com/pablo14/funModeling/issues>.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```

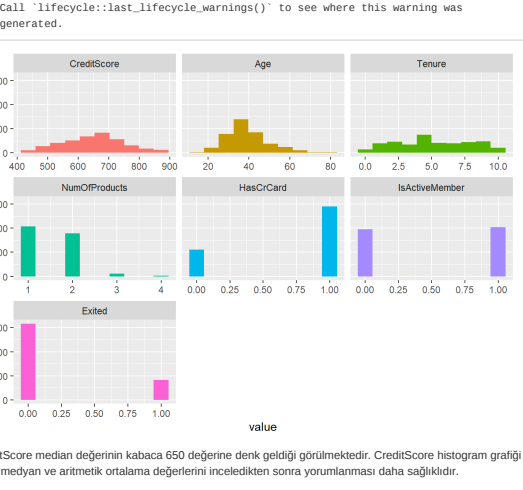

CreditScore median değerinin kabaca 650 değerine denk geldiği görülmektedir. CreditScore histogram grafiği simetrik gibi görünmektedir, ancak mod, medyan ve aritmetik ortalama değerlerini inceledikten sonra yorumlanması daha sağlıklıdır.

Age kategorisi için veri merkezi kabaca 30-40 değerleri aralığında olduğu görülmektedir. Sağa çarpık bir grafiktir. Bu da aritmetik ortalama > medyan > mod sıralamasını vermektedir.

"HasCrCard" değişkeni için,müşterilerin çoğunluğunun bir kredi kartına sahip olduğunu göstermektedir.

"Tenure" değişkeni için, 4 ile5 yıl memuriyet süresine sahip kişiler çoğunluğu oluşturmaktadır yorumu yapılabilir.

"NumOfProducts" değişkeni için, ortalama ürün sayısı en çok 1 olmakla birlikte buna çok yakın bir oranla müşterilerin 2 ürüne sahip olduğu söylenebilir. Bu da ortalama olarak ürün sayısının 1.51-1.55 aralığında olduğu yorumu yapılır. Müşterilerin çok az bir kısmı ise 4 adet ürüne sahiptir.

"Hascart" değişkeni için, müşterilerin bir karta sahip olma oranı yüksektir denilebilir.

"IsActiveMember" değişkeni için, üyelerin yaklaşık yarısı aktifken diğer yarısı pasiftir yorumu yapılabilir.

```
#niceller uzerinden
profiling_num(train)
```

```
##         variable      mean    std_dev variation_coef p_01   p_05 p_25 p_50 p_75
## 1    CreditScore 649.29250 98.5668744      0.1518066  433 483.95  582  655  714
## 2            Age  39.21625 10.1911388      0.2598703   22  25.00   33   38   44
## 3         Tenure   5.18875  2.9204083      0.5628346    0   1.00    3    5    8
## 4  NumOfProducts   1.52500  0.5956665      0.3906010    1   1.00    1    1    2
## 5      HasCrCard   0.72375  0.4474217      0.6181992    0   0.00    0    1    1
## 6 IsActiveMember   0.51125  0.5001861      0.9783592    0   0.00    0    1    1
## 7         Exited   0.20875  0.4066696      1.9481178    0   0.00    0    0    0
##     p_95   p_99    skewness kurtosis iqr    range_98     range_80
## 1 819.05 850.00 -0.06769939 2.518432 132  [433, 850] [515, 777.1]
## 2  60.00  67.03  0.96008460 4.147596  11 [22, 67.03]     [28, 54]
## 3   9.05  10.00 -0.06873708 1.791478   5     [0, 10]       [1, 9]
## 4   2.00   3.00  0.09902661 4.098569   1      [1, 3]       [1, 2]
## 5   1.00   1.00 -1.00008072 2.001602   1      [0, 1]       [0, 1]
## 6   1.00   1.00 -0.04501139 1.002026   1      [0, 1]       [0, 1]
## 7   1.00   1.00  1.43326279 3.054242   0      [0, 1]       [0, 1]
```

Yukarıdaki tabloya göre:

"CreditScore" değişkeninin ortalama kredi skoru 649.29'dur ve standart sapması 98.56'dır.

"Age" değişkeninin ortalama yaşı 39.21'dir ve standart sapması 10.19'dur.

"Tenure" değişkeni, ortalama müşteri süresi olarak 5.18'i göstermektedir ve standart sapması 2.92'dir.

"NumOfProducts" değişkeni için, ortalama ürün sayısı 1.52'dir ve standart sapması 0.59'dur. Bu, müşterilerin genellikle 1 veya 2 ürüne sahip olduğunu göstermektedir.

"HasCrCard" değişkeni için, ortalama kart sahipliği oranı 0.72'dir ve standart sapması 0.44'tür. Bu, müşterilerin çoğunluğunun bir kredi kartına sahip olduğunu göstermektedir.

"IsActiveMember" değişkeni için, ortalama aktif üye oranı 0.51'dir ve standart sapması 0.50'dir. Bu, müşterilerin yaklaşık yarısının aktif üyeler olduğunu göstermektedir.

"Exited" değişkeni için, ortalama churn (müşteri kaybı) oranı 0.21'dir ve standart sapması 0.41'dir. Bu, müşterilerin yaklaşık %20'sinin kaybedildiğini göstermektedir.

Yaş kategorisini incelediğimizde, müşterilerin %73 ünü 26-45 yaş arasındaki orta yaş kategorisinin oluşturduğu, en az müşterinin ise %1.75 oranında 65 yaşın üzerindeki ileri yaşlı kişilerin oluşturduğu yorumu yapılabilir.

```
library(ggplot2)
library(dplyr)

# Kategorize edilen yaşa göre frekansları hesapla
freq_percent <- train %>%
  count(Yas_kat) %>%
  mutate(percent = n/sum(n) * 100)

# Pasta grafiği oluştur
ggplot(freq_percent, aes(x = "", y = percent, fill = factor(Yas_kat))) +
  geom_bar(width = 1, stat = "identity") +
  coord_polar(theta = "y") +
  labs(x = "", y = "", fill = "Age Category") +
  ggtitle("Percentage Distribution of Age Category") +
  scale_fill_discrete(name = "Age Category") +
  theme_void() +
  theme(plot.title = element_text(hjust = 0.5)) +
  geom_text(aes(label = paste0(percent, "%")), position = position_stack(vjust = 0.5))
```

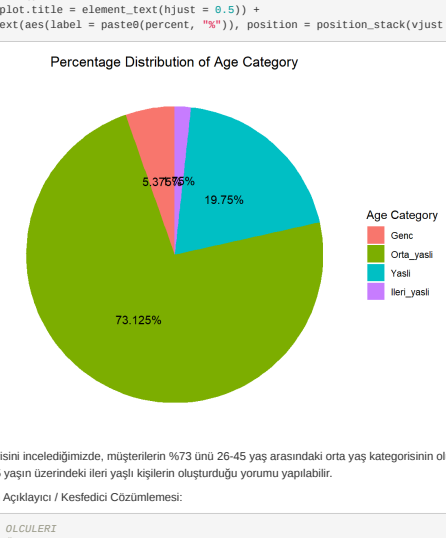

Yaş kategorisini incelediğimizde, müşterilerin %73 ünü 26-45 yaş arasındaki orta yaş kategorisinin oluşturduğu, en az müşterinin ise %1.75 oranında 65 yaşın üzerindeki ileri yaşlı kişilerin oluşturduğu yorumu yapılabilir.

###Verilerin Açıklayıcı / Keşfedici Çözümlemesi:

```
###NOKTA OLCULERI
#3 Nokta Özeti
n <- nrow(train)
train_sorted <- train[order(train$CreditScore),] #ascending
#ortnc_derinlik<-(n+1)/2 #tek sayı ise
#cift ise:
a <- (n/2)
b <- (n/2)+1
(train_sorted$Gender[a] + train_sorted$CreditScore[b])/2
```

```
## Warning in Ops.factor(train_sorted$Gender[a], train_sorted$CreditScore[b]): '+'
## not meaningful for factors
```

```
## [1] NA
```

```
median(train$CreditScore)
```

```
## [1] 655
```

```
mean(train$CreditScore)
```

```
## [1] 649.2925
```

```
hist(train$CreditScore)
```

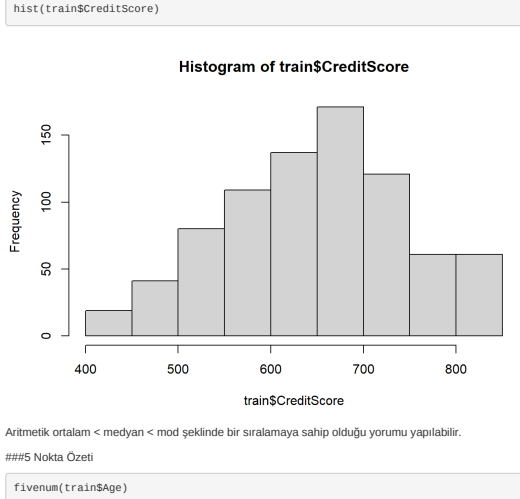

CreditScore verileri sola çarpıktır.

Aritmetik ortalama < medyan < mod şeklinde bir sıralamaya sahip olduğu yorumu yapılabilir.

###5 Nokta Özeti

```
fivenum(train$Age)
```

```
## [1] 18 33 38 44 83
```

```
#or:
quantile(train$Age) # Quantiles
```

```
##   0%  25%  50%  75% 100% 
##   18   33   38   44   83 
```

```
quantile(train$Age, c(.1, .9)) # Customized quantiles
```

```
## 10% 90% 
##  28  54 
```

```
q1 <- as.vector(quantile(train$Age,0.25))
q3 <- as.vector(quantile(train$Age,0.75))
DAG <- q3-q1
DAG
```

```
## [1] 11
```

```
genislik <- max(train$Age)-min(train$Age)
genislik
```

```
## [1] 65
```

"Age" (Yaş) değişkeninin 5 nokta özeti aşağıdaki şekildedir:

Minimum değer: 18 çeyrek (25. persentil): 33 Medyan (50. persentil): 38 çeyrek (75. persentil): 44 Maksimum değer: 83

Özelleştirilmiş quantile değerleri, 10% ve 90% persentillerine karşılık gelen değerleri gösterir. Bu değerler, yaş değerlerinin daha özelleştirilmiş persentillere göre dağılımını ifade eder. Örneğin, 10% persentil değeri 28, 90% persentil değeri ise 54 olarak hesaplanmıştır.

###DEGISIM OLCULERI:

```
stdev <- sd(train$Age)
mean <- mean(train$Age)
Degisim_kats_age <- (stdev/mean)*100
```

###Cinsiyete göre kredi skorlarının yayılımı için:

```
sd_dk <- function(x) {c(std<-sd(x), dk<-(sd(x)/mean(x))*100)}
tapply(train$CreditScore, train$Gender, sd_dk)
```

```
## $`0`
## [1] 100.62796  15.49303
##
## $`1`
## [1] 96.04825 14.79884
```

0 kategorisi (erkekler):

Standart sapma (std): 100.62796 Değişim katsayısı (dk): 15.49303

1 kategorisi (kadınlar):

Standart sapma (std): 96.04825 Değişim katsayısı (dk): 14.79884

Standart sapma, bir veri setindeki değerlerin ortalama etrafında ne kadar yayıldığını ölçerken, değişim katsayısı ise standart sapmayı ortalama değere göre oransal olarak ifade eder. Grup 0 ve 1 arasındaki standart sapma ve değişim katsayısı farklarına dayanarak, bu iki grup arasında CreditScore değişkeninin dağılımında belirli bir farklılık olduğu söyleyebiliriz.

###MAD(Median Absolute Deviation):

```
sort <- train[order(train$Age),]
medianf <- median(sort$Age)
sort$fmed <- abs(sort$Age-medianf)
sort2 <- sort[order(sort$fmed),]
mad <- median(sort2$fmed)
```

###Genişletilmiş Nokta Özeti

```
#Sol kuyruk
sol <- function(x) {
  c(quantile(x, probs = 1/2) ,
    quantile(x, probs = 1/4),
    quantile(x, probs =1/8 ),
    quantile(x,probs=1/16),
    quantile(x,probs=1/32),
    quantile(x,probs=1/64)
  )
}
#Sag kuyruk
sag <- function(x) {
  c(quantile(x, probs = 1/2) ,
    quantile(x, probs = 3/4),
    quantile(x, probs = 7/8),
    quantile(x,probs=15/16),
    quantile(x,probs=31/32),
    quantile(x,probs=63/64)
  )
}
```

```
#cinsiyete gore sol kuyruk
y <- tapply(train$Age, train$Gender, sol)
mrg_cins <- as.data.frame(cbind(y[[1]],y[[2]]))
colnames(mrg_cins) <- c("Female","Male")
mrg_cins$Fark <- abs(mrg_cins$Female-mrg_cins$Male)
mrg_cins
```

```
##           Female Male     Fark
## 50%     37.00000   38 1.000000
## 25%     33.00000   32 1.000000
## 12.5%   30.00000   28 2.000000
## 6.25%   27.00000   26 1.000000
## 3.125%  24.00000   24 0.000000
## 1.5625% 23.95312   22 1.953125
```

Female (kadınlar):

Medyan: 37 çeyrek (25%): 33 12.5. yüzdelik: 30 6.25. yüzdelik: 27 3.125. yüzdelik: 24 1.5625. yüzdelik: 23

Male (erkekler):

Medyan: 38 çeyrek (25%): 32 12.5. yüzdelik: 28 6.25. yüzdelik: 26 3.125. yüzdelik: 24 1.5625. yüzdelik: 22

Fark sütunu, kadınlar ve erkekler arasındaki yaşın sol kuyruğunda ortaya çıkan farkı göstermektedir. Pozitif fark değerleri, kadınların yaşının erkeklerden daha büyük olduğunu gösterirken, negatif fark değerleri erkeklerin yaşının kadınlardan daha büyük olduğunu gösterir.

Bu çıktılara dayanarak, cinsiyete göre yaşın sol kuyruğunda belirli bir fark olduğu görülmektedir. Ancak, farkın büyüklüğünü değerlendirmek ve anlamlı olup olmadığını belirlemek için daha fazla analiz yapılması gerekebilir.

```
#Kuyruk Uzunlugu Incelemesi
x_a <- sol(train$Tenure)
x_u <- sag(train$Tenure)
x_mrg <- as.data.frame(cbind(x_a,x_u))
rownames(x_mrg) <- c("1/2","1/4","1/8","1/16","1/32","1/64")
colnames(x_mrg) <- c("Alt_Kuyruk","Ust_Kuyruk")
x_mrg$orta_nokta <- (x_mrg$Alt_Kuyruk+x_mrg$Ust_Kuyruk)/2
x_mrg
```

```
##      Alt_Kuyruk Ust_Kuyruk orta_nokta
## 1/2           5          5        5.0
## 1/4           3          8        5.5
## 1/8           1          9        5.0
## 1/16          1          9        5.0
## 1/32          0         10        5.0
## 1/64          0         10        5.0
```

```
hist(train$Tenure)
```

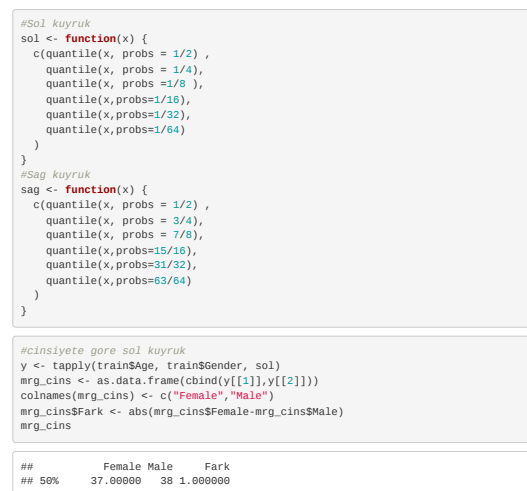

Kesilmiş Ortalama:

```
p <- 0.1
mean(train$Tenure, trim = p)
```

```
## [1] 5.21875
```

```
#Kalan gozlem sayisi hesaplanmak istenirse:
n <- nrow(train)
ks <-n-(as.integer(2*p*n))
ks
```

```
## [1] 640
```

Burada,train veri setindeki Tenure değişkeninin, %10 trimlenmiş ortalaması hesaplanmaktadır. Trimleme, veri setinin en düşük ve en yüksek p yüzde değerini keserek, aşırı değerlerin etkisini azaltmaya yönelik bir işlemdir.

Çıktıya göre:

%10 trimlenmiş ortalama değeri 5.21875 olarak hesaplanmıştır. Bu değer, Tenure değişkeninin aşırı değerlerden arındırılmış ortalama değeridir. Ayrıca, ks değişkeniyle n gözlem sayısından %10 trimleme yapıldığında kaç gözlemin kaldığını hesaplamışsınız. Bu durumda, 640 gözlem kaldığı görülmektedir.

###Geometrik ortalama:

```
geometric.mean(train$Age)
```

```
## [1] 37.99447
```

Burada ise, train veri setindeki Age değişkeninin geometrik ortalaması hesaplanmaktadır. Geometrik ortalama, veri setindeki değerlerin çarpımının nüfusa (gözlem sayısına) göre hesaplanan bir ölçüdür.

Geometrik ortalamayı kullanarak, Age değişkeninin değerlerinin çoğunlukla 37.99447 civarında yoğunlaştığını ve dağılımın genel bir eğilim gösterdiği söylenebilir.

Entropi

```
freq <- as.data.frame(table(train$Gender))
names(freq)[1] <- 'Gender'

entropy <- function(base, a, b) {
  var <-  abs((a / (a + b)) * log((a / (a + b)), base)) - ((b / (a + b)) * log((b / (a + b)), base))
  return(var)
}

ent <- entropy(10, freq[1, "Freq"], freq[2, "Freq"])
k <- 2
ent / log(k, 10)
```

```
## [1] 0.990439
```

Bu değer, veri kümesindeki kategorilerin düzensizlik veya belirsizlik düzeyini temsil etmektedir. Değerin 1'e yaklaşması, veri kümesindeki kategorilerin eşit olarak dağıldığı ve düzensizlik veya belirsizlik düzeyinin yüksek olduğunu gösterir.

Cinsiyet Dağılımı Bar Plot

```
bar_plot <- ggplot(train, aes(Gender)) +
  geom_bar(aes(fill = Gender)) +
  xlab("Cinsiyet") +
  ylab("Frekanslar") +
  ggtitle("Cinsiyet Dağılımı") +
  scale_fill_discrete(name = "Cinsiyet")

# Bar Plot üzerine değerleri yazdırma
bar_plot +
  geom_text(
    stat = "count",
    aes(label = ..count..),
    vjust = -0.5,
    color = "black",
    size = 3
  )
```

```
## Warning: The dot-dot notation (`..count..`) was deprecated in ggplot2 3.4.0.
## ℹ Please use `after_stat(count)` instead.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```

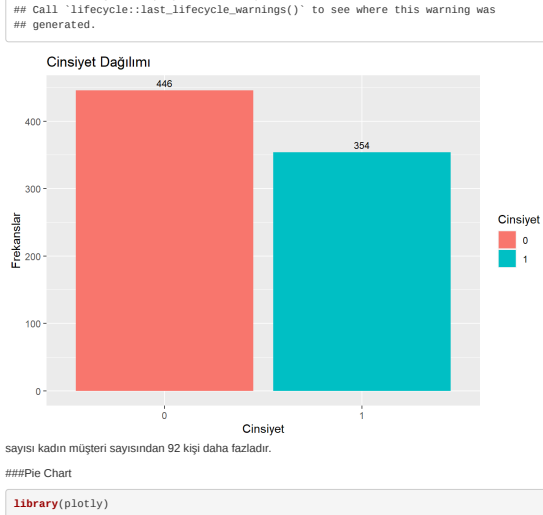

Veri kümesindeki erkek müşteri sayısı kadın müşteri sayısından 92 kişi daha fazladır.

###Pie Chart

```
library(plotly)
```

```
##
## Attaching package: 'plotly'
```

```
## The following object is masked from 'package:Hmisc':
##
##     subplot
```

```
## The following object is masked from 'package:MASS':
##
##     select
```

```
## The following object is masked from 'package:ggplot2':
##
##     last_plot
```

```
## The following object is masked from 'package:stats':
##
##     filter
```

```
## The following object is masked from 'package:graphics':
##
##     layout
```

```
cross<-as.data.frame(prop.table(table(train$Tenure)))
colnames(cross)[1] <- "Tenure"
plot_ly(cross, labels = ~Tenure, values = ~Freq, type = 'pie')%>% layout(title ='Tenure Degişkenindeki Dağılım')
```

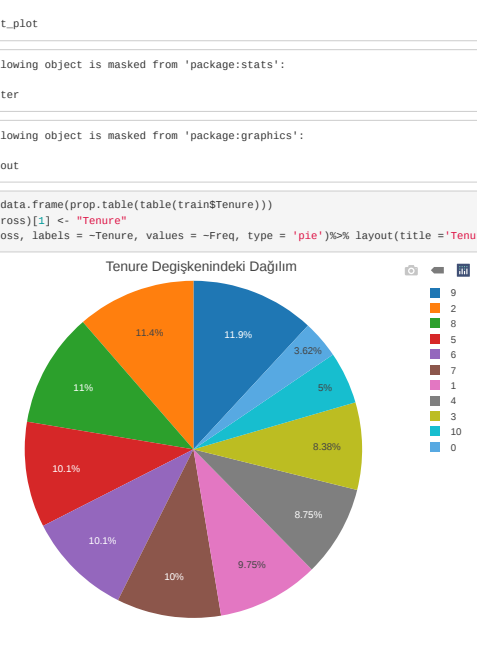

Yukarıdaki pie chart grafiğine göre, en çok tekrarlayan çalışma süresi 9 iken, en az çalışma süresi 0 ve 10 dur yorumu yapılabilir.

###2kategorikle çubuk grafiği oluşturma:

```
ggplot(train,aes(Yas_kat, fill=Gender))+
  geom_bar(position=position_dodge())+
  ggtitle("Yaş Kategorilerindeki Cinsiyet Dağılımı")+
  xlab("Yaş Kategorileri")+
  ylab("Sıklıklar")+
  scale_fill_discrete(name = "Cinsiyet")+
  theme(axis.title.x = element_text(color="black", face="bold", size=12),
        axis.title.y = element_text(color="black", face="bold",size=12),
        plot.title = element_text(hjust = 0.5,color="black", face="bold", size=14),
        legend.title = element_text(colour="black",face="bold",size=12))
```

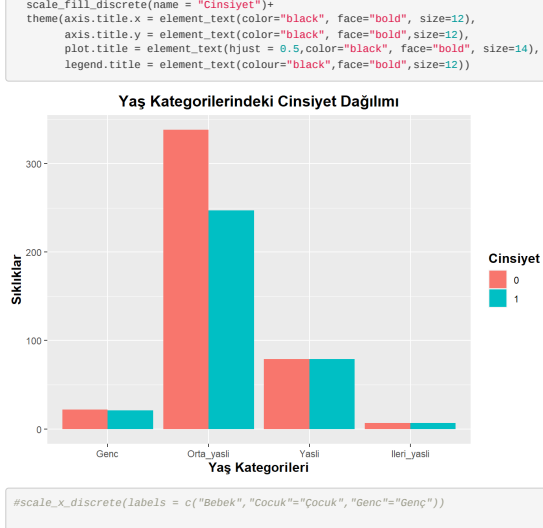

```
#scale_x_discrete(labels = c("Bebek","Cocuk"="Çocuk","Genc"="Genç"))

#Count eklenerek:
ggplot(train, aes(Yas_kat, fill = Gender)) +
  geom_bar() +
  geom_text(aes(label=..count..),stat="count",position=position_stack(0.5))
```

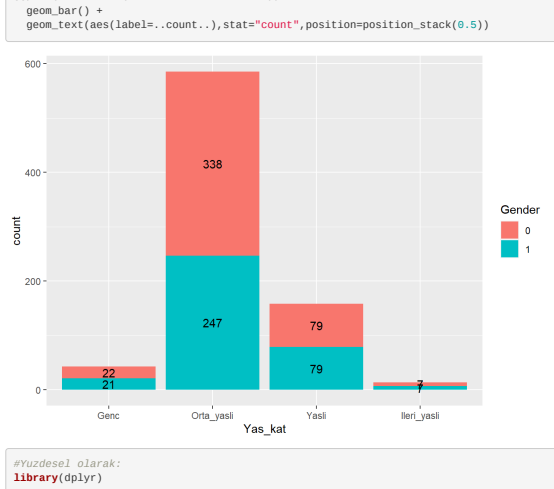

```
#Yuzdesel olarak:
library(dplyr)
tra_pct <- train %>% group_by(Yas_kat, Gender) %>%
  dplyr::summarise(count=n()) %>%
  mutate(pct=round(count/sum(count),2))
```

```
## `summarise()` has grouped output by 'Yas_kat'. You can override using the
## `.groups` argument.
```

```
ggplot(tra_pct, aes(Yas_kat, pct, fill = Gender)) +
  geom_bar(stat='identity') +
  geom_text(aes(label=scales::percent(pct)), position = position_stack(vjust = .5))+
  scale_y_continuous(labels = scales::percent)
```

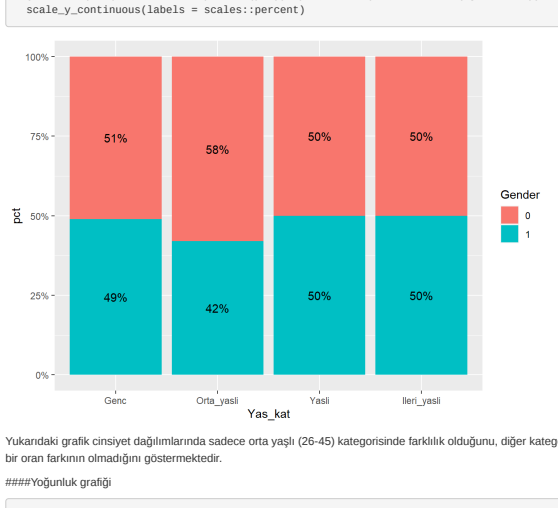

Yukarıdaki grafik cinsiyet dağılımlarında sadece orta yaşlı (26-45) kategorisinde farklılık olduğunu, diğer kategorilerde önem yaratacak kadar büyük bir oran farkının olmadığını göstermektedir.

###Yoğunluk grafiği

```
ggplot(train, aes(x = CreditScore)) +
  geom_density()
```

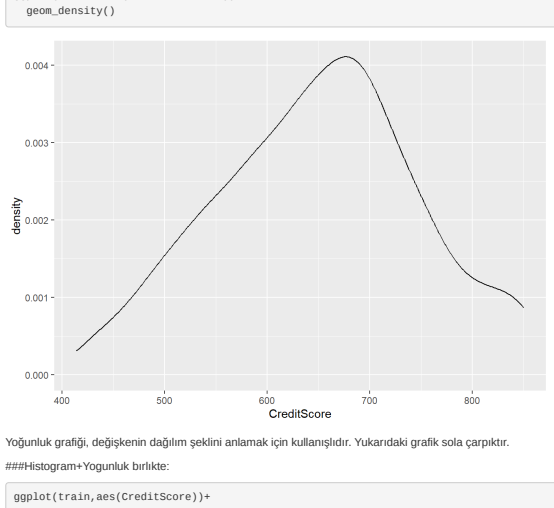

Yoğunluk grafiği, değişkenin dağılım şeklini anlamak için kullanılıyor. Yukarıdaki grafik sola çarpıktır.

###Histogram+Yogunluk birlikte:

```
ggplot(train,aes(CreditScore))+
  geom_histogram(aes(y=..density..), fill="white", color="black")+
  geom_density(alpha=.4,fill="blue")
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```

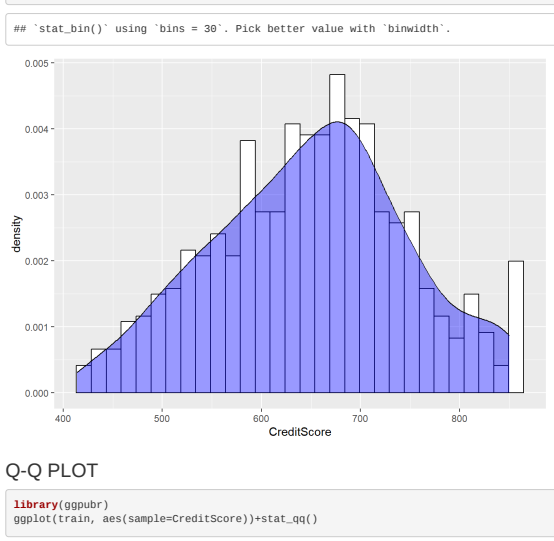

Q-Q PLOT

```
library(ggpubr)
ggplot(train, aes(sample=CreditScore))+stat_qq()
```

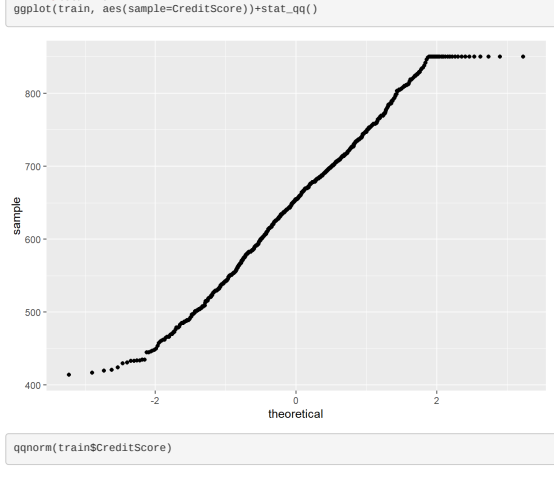

```
qqnorm(train$CreditScore)
```

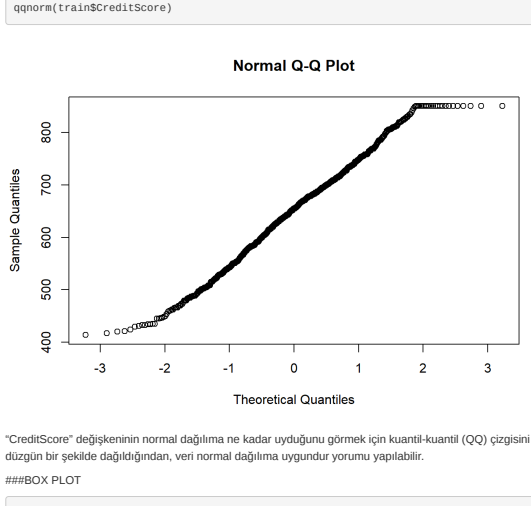

"CreditScore" değişkeninin normal dağılıma ne kadar uyduğunu görmek için kuantil-kuantil (QQ) çizgisini çizilmiştir. Noktaların büyük çoğunluğu düzgün bir şekilde dağıldığından, veri normal dağılıma uygundur yorumu yapılabilir.

###BOX PLOT

```
ggplot(train, aes(y=Tenure))+
  geom_boxplot()
```

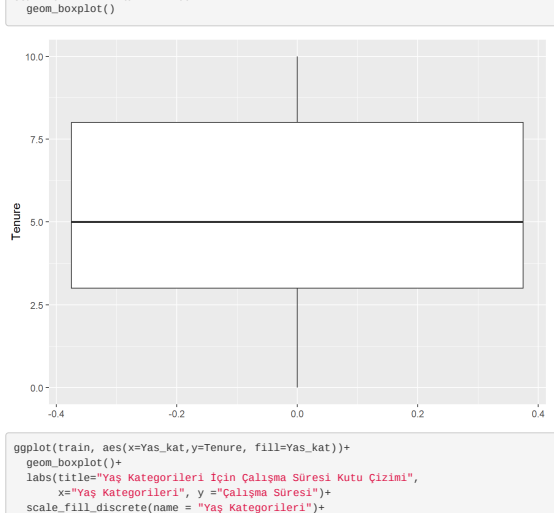

```
ggplot(train, aes(x=Yas_kat,y=Tenure, fill=Yas_kat))+
  geom_boxplot()+
  labs(title="Yaş Kategorileri İçin Çalışma Süresi Kutu Çizimi",
       x="Yaş Kategorileri", y ="Çalışma Süresi")+
  scale_fill_discrete(name = "Yaş Kategorileri")+
  stat_summary(fun = median, geom="line", group= 1, color= "black", size = 1)
```

```
## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
## ℹ Please use `linewidth` instead.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```

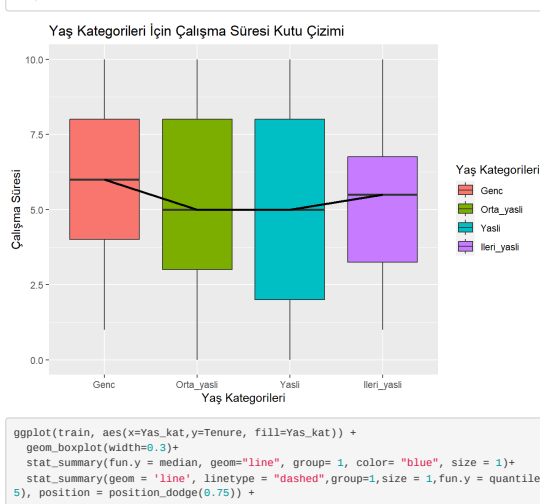

```
ggplot(train, aes(x=Yas_kat,y=Tenure, fill=Yas_kat)) +
  geom_boxplot(width=0.3)+
  stat_summary(fun.y = median, geom="line", group= 1, color= "blue", size = 1)+
  stat_summary(geom = 'line', linetype = "dashed",group=1,size = 1,fun.y = quantile, fun.args = list(probs = 0.2
5), position = position_dodge(0.75)) +
  stat_summary(geom = 'line', group= 1,linetype = "dashed",size = 1, fun.y = quantile, fun.args = list(probs = 0.
75), position = position_dodge(0.75))
```

```
## Warning: The `fun.y` argument of `stat_summary()` is deprecated as of ggplot2 3.3.0.
## ℹ Please use the `fun` argument instead.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```

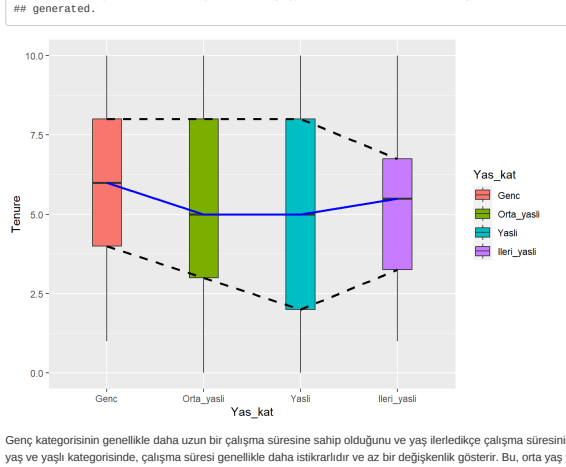

Genç kategorisinin genellikle daha uzun bir çalışma süresine sahip olduğunu ve yaş ilerledikçe çalışma süresinin azaldığını göstermektedir.Orta yaş ve yaşlı kategorisinde, çalışma süresi genellikle daha istikrarlıdır ve az bir değişkenlik gösterir. Bu, orta yaş ve yaşlı kategorisindeki kişilerin genellikle benzer bir çalışma süresine sahip olduğunu gösterir.Ileri yaşlı kategorisinde, çalışma süresinde bir artış eğilimi gözlemlenebilir. Bu, ileri yaşlarda bazı erkeklerin tekrar daha uzun bir çalışma süresine sahip olduğunu göstermektedir.

Bu bulgular, yaş grupları arasında çalışma süreleri konusunda farklılıklar olduğunu ve yaşın çalışma süresi üzerinde etkili olduğunu göstermektedir.

Ucdegerlerin rengini ve seklini degistirme:

```
ggplot(train, aes(x=Yas_kat,y=CreditScore, fill=Yas_kat)) +
  geom_boxplot(outlier.colour="red", outlier.shape=8,
               outlier.size=1)
```

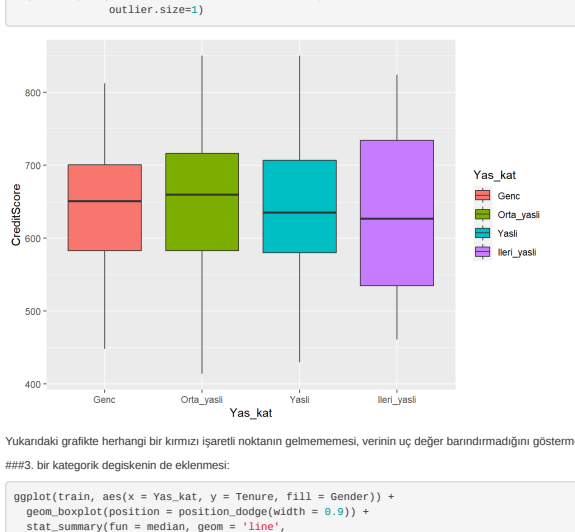

Yukarıdaki grafikte herhangi bir kırmızı işaretli noktanın gelmemesi, verinin uç değer barındırmadığını göstermektedir.

###3. bir kategorik degiskenin de eklenmesi:

```
ggplot(train, aes(x = Yas_kat, y = Tenure, fill = Gender)) +
  geom_boxplot(position = position_dodge(width = 0.9)) +
  stat_summary(fun = median, geom = 'line',
               aes(group = Gender), size = 1, color = "green",
               position = position_dodge(width = 0.9))
```

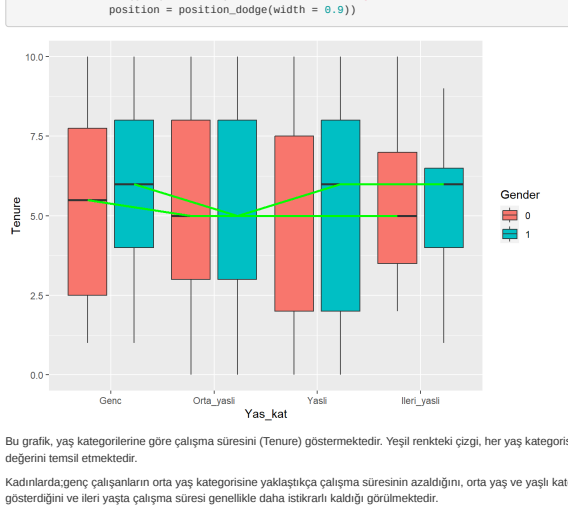

Bu grafik, yaş kategorilerine göre çalışma süresini (Tenure) göstermektedir. Yeşil renkteki çizgi, her yaş kategorisi için çalışma süresinin ortanca değerini temsil etmektedir.

Kadınlardaçgenç çalışanların orta yaş kategorisine yaklaşıkça çalışma süresinin azaldığı, orta yaş ve yaşlı kategorisi arasında tekrar artış gösterdiğini ve ileri yaşta çalışma süresi genellikle daha istikrarlı kaldığı görülmektedir.

Erkeklerde ise; genç erkeklerin genellikle daha uzun bir çalışma süresine sahip olduğunu ve orta yaşa yaklaştıkça çalışma süresinin azaldığını ancak daha sonraki yaşlarda çalışma süresinin genellikle daha istikrarlı kaldığı görülmektedir.

Tenure - CreditScore

```
ggplot(train, aes(Tenure, CreditScore)) +
  geom_point() +
  geom_smooth(method = "loess", col = "red", se = FALSE)
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

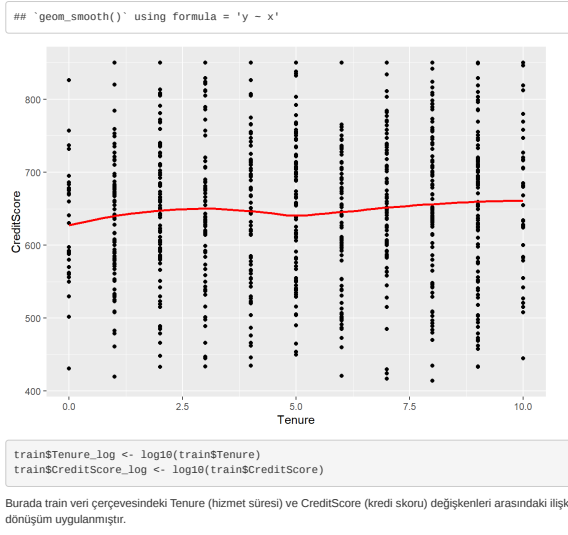

```
train$Tenure_log <- log10(train$Tenure)
train$CreditScore_log <- log10(train$CreditScore)
```

Burada train veri çerçevesindeki Tenure (hizmet süresi) ve CreditScore (kredi skoru) değişkenleri arasındaki ilişki görselleştirilmiş ve logaritmik dönüşüm uygulanmıştır.

Hafif bir kıvrım ve eğim değişiklikleri ile çizginin neredeyse düz bir şekilde gelmesi doğrusal bir ilişkiyi desteklemektedir.Yani, CreditScore değeri Tenure ile doğrusal bir şekilde artıyor veya azalıyor denilebilir.

###Saçılım grafiğindeki noktaları sayısal olarak görmek için:

```
hist(train$Tenure_log, col = "lightpink", main = "Log(Tenure)")
```

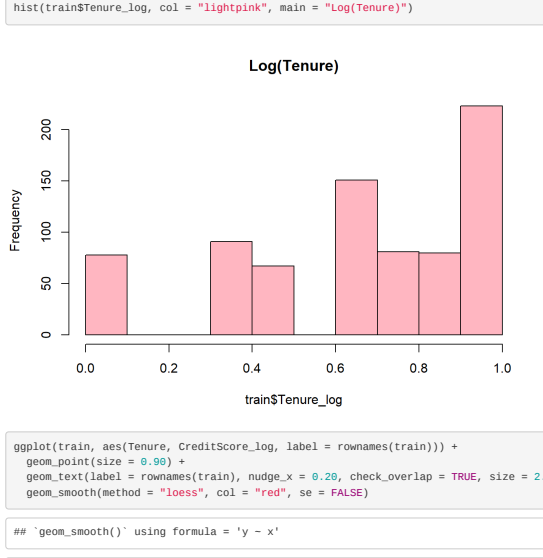

```
ggplot(train, aes(Tenure, CreditScore_log, label = rownames(train))) +
  geom_point(size = 0.90) +
  geom_text(label = rownames(train), nudge_x = 0.20, check_overlap = TRUE, size = 2.5) +
  geom_smooth(method = "loess", col = "red", se = FALSE)
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning: The following aesthetics were dropped during statistical transformation: label
## ℹ This can happen when ggplot fails to infer the correct grouping structure in
##   the data.
## ℹ Did you forget to specify a `group` aesthetic or to convert a numerical
##   variable into a factor?
```

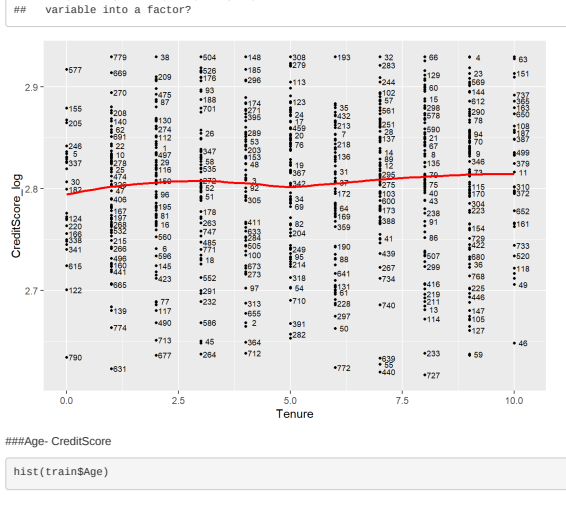

###Age- CreditScore

```
hist(train$Age)
```

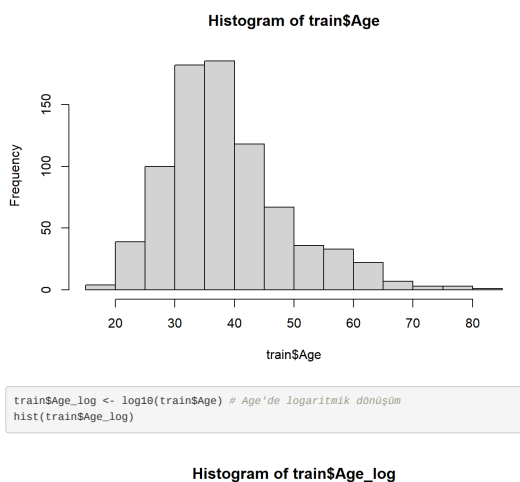

```
train$Age_log <- log10(train$Age) # Age'de logaritmik dönüşüm
hist(train$Age_log)
```

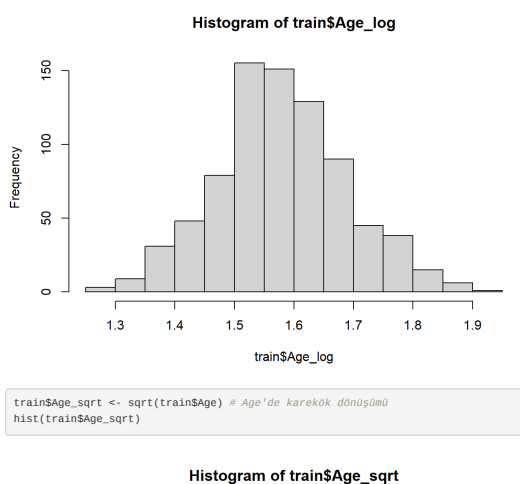

```
train$Age_sqrt <- sqrt(train$Age) # Age'de karekök dönüşümü
hist(train$Age_sqrt)
```

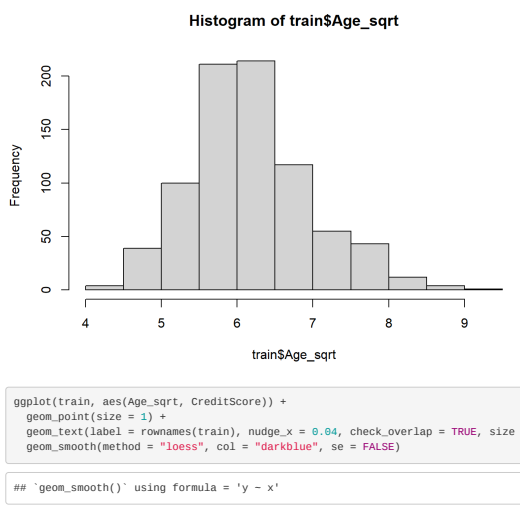

```
ggplot(train, aes(Age_sqrt, CreditScore)) +
  geom_point(size = 1) +
  geom_text(label = rownames(train), nudge_x = 0.04, check_overlap = TRUE, size = 2.5) +
  geom_smooth(method = "loess", col = "darkblue", se = FALSE)
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

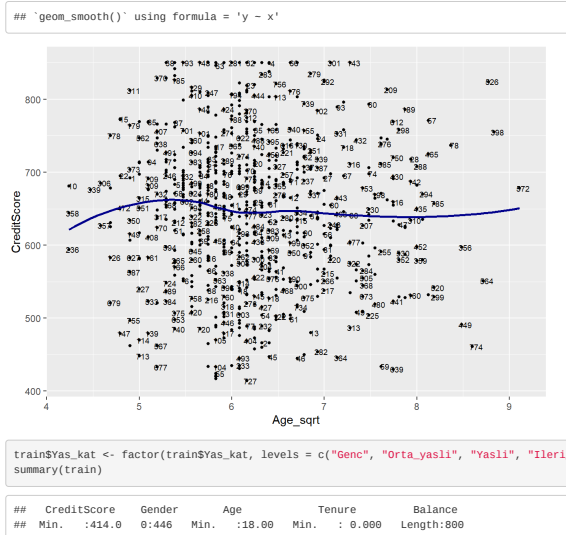

```
train$Yas_kat <- factor(train$Yas_kat, levels = c("Genc", "Orta_yasli", "Yasli", "Ileri_yasli"))
summary(train)
```

```
##   CreditScore    Gender      Age            Tenure          Balance         
##  Min.   :414.0   0:446   Min.   :18.00   Min.   : 0.000   Length:800        
##  1st Qu.:582.0   1:354   1st Qu.:33.00   1st Qu.: 3.000   Class :character  
##  Median :655.0           Median :38.00   Median : 5.000   Mode  :character  
##  Mean   :649.3           Mean   :39.22   Mean   : 5.189                     
##  3rd Qu.:714.0           3rd Qu.:44.00   3rd Qu.: 8.000                     
##  Max.   :850.0           Max.   :83.00   Max.   :10.000                     
##  NumOfProducts     HasCrCard      IsActiveMember   EstimatedSalary   
##  Min.   :1.000   Min.   :0.0000   Min.   :0.0000   Length:800        
##  1st Qu.:1.000   1st Qu.:0.0000   1st Qu.:0.0000   Class :character  
##  Median :1.000   Median :1.0000   Median :1.0000   Mode  :character  
##  Mean   :1.525   Mean   :0.7238   Mean   :0.5112                     
##  3rd Qu.:2.000   3rd Qu.:1.0000   3rd Qu.:1.0000                     
##  Max.   :4.000   Max.   :1.0000   Max.   :1.0000                     
##      Exited              Yas_kat      Tenure_log     CreditScore_log
##  Min.   :0.0000   Genc       : 43   Min.   :  -Inf   Min.   :2.617  
##  1st Qu.:0.0000   Orta_yasli :585   1st Qu.:0.4771   1st Qu.:2.765  
##  Median :0.0000   Yasli      :158   Median :0.6990   Median :2.816  
##  Mean   :0.2087   Ileri_yasli: 14   Mean   :  -Inf   Mean   :2.807  
##  3rd Qu.:0.0000                     3rd Qu.:0.9031   3rd Qu.:2.854  
##  Max.   :1.0000                     Max.   :1.0000   Max.   :2.929  
##     Age_log         Age_sqrt    
##  Min.   :1.255   Min.   :4.243  
##  1st Qu.:1.519   1st Qu.:5.745  
##  Median :1.580   Median :6.164  
##  Mean   :1.580   Mean   :6.213  
##  3rd Qu.:1.643   3rd Qu.:6.633  
##  Max.   :1.919   Max.   :9.110  
```

```
is_outlier <- function(x) {
  return(x < quantile(x, 0.25) - 1.5 * IQR(x) | x > quantile(x, 0.75) + 1.5 * IQR(x))
}

library(dplyr)

dat <- train %>%
  tibble::rownames_to_column(var = "outlier") %>%
  group_by(Yas_kat) %>%
  mutate(is_outlier = ifelse(is_outlier(CreditScore_log), CreditScore_log, as.numeric(NA)))

dat$outlier[which(is.na(dat$is_outlier))] <- as.numeric(NA)

ggplot(dat, aes(y = CreditScore_log, x = factor(Yas_kat), fill = Yas_kat)) +
  geom_boxplot() +
  geom_text(aes(label = outlier), na.rm = TRUE, nudge_x = 0.15, size = 3.5) +
  labs(title = "Yas kategorileri bazında log(CreditScore) Kutu Çizimi", x = "Yas Kategorileri", y = "log(CreditSc
ore)") +
  scale_fill_discrete(name = "Yas Kategorileri")
```

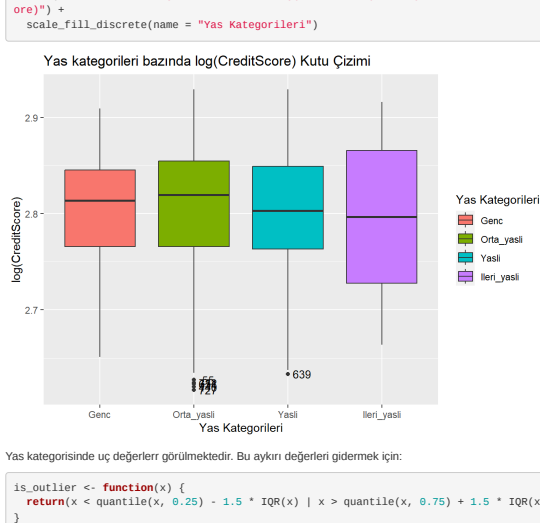

Yas kategorisinde uç değerler görülmektedir. Bu aykırı değerleri gidermek için:

```
is_outlier <- function(x) {
  return(x < quantile(x, 0.25) - 1.5 * IQR(x) | x > quantile(x, 0.75) + 1.5 * IQR(x))
}

train$Yas_kat <- factor(train$Yas_kat, levels = c("Genc", "Orta_yasli", "Yasli", "Ileri_yasli"))

dat <- train %>%
  tibble::rownames_to_column(var = "outlier") %>%
  group_by(Yas_kat) %>%
  mutate(is_outlier = ifelse(is_outlier(CreditScore_log), CreditScore_log, as.numeric(NA)))

dat$outlier[which(is.na(dat$is_outlier))] <- as.numeric(NA)

filtered_dat <- dat %>%
  mutate(CreditScore_log = ifelse(!is.na(is_outlier), NA, CreditScore_log)) %>%
  filter(!is.na(CreditScore_log))

ggplot(filtered_dat, aes(y = CreditScore_log, x = factor(Yas_kat), fill = Yas_kat)) +
  geom_boxplot() +
  labs(title = "Yas kategorileri bazında log(CreditScore) Kutu Çizimi", x = "Yas Kategorileri", y = "log(CreditSc
ore)") +
  scale_fill_discrete(name = "Yas Kategorileri")
```

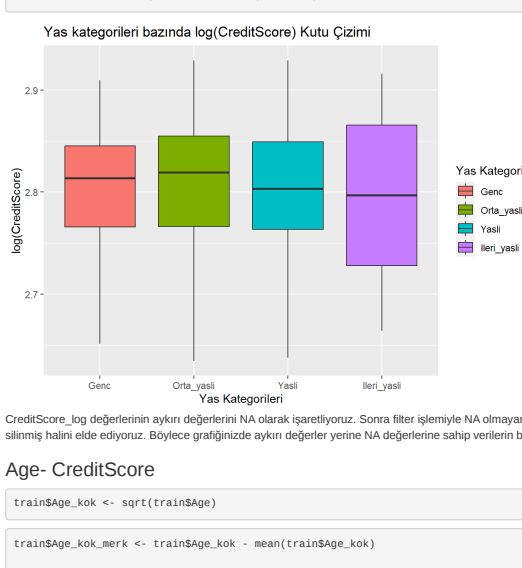

Bu kodda, mutate işlemi içinde CreditScore_log değerlerinin aykırı değerlerini NA olarak işaretliyoruz. Sonra filter işlemiyle NA olmayan değerleri filtreleyerek aykırı değerlerin silinmiş halini elde ediyoruz. Böylece grafiğimizde aykırı değerler yerine NA değerlerine sahip verilerin bulunduğu bir kutu grafiği elde edebiliriz.

## Age- CreditScore

```
train$Age_kok <- sqrt(train$Age)
```

```
train$Age_kok_merk <- train$Age_kok - mean(train$Age_kok)

library(ggplot2)

ggplot(train, aes(x = Age_kok_merk, y = CreditScore_log)) +
  stat_smooth(method = "lm", se = FALSE, color = "green", formula = y ~ x) +
  stat_smooth(method = "lm", se = FALSE, color = "blue", formula = y ~ x + I(x ^ 2)) +
  stat_smooth(method = "lm", se = FALSE, color = "red", formula = y ~ x + I(x ^ 2) + I(x ^ 3)) +
  geom_point(colour = "black", size = 1)
```

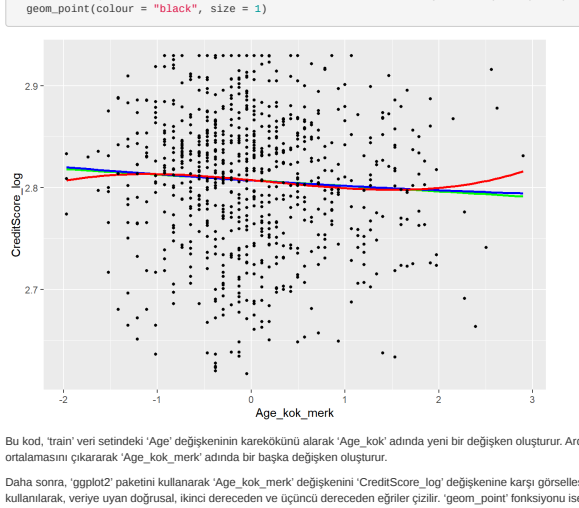

Bu kod, 'train' veri setindeki 'Age' değişkeninin karekökünü alarak 'Age_kok' adında yeni bir değişken oluşturur. Ardından, 'Age_kok' değişkeninin ortalamasını çıkararak 'Age_kok_merk' adında bir başka değişken oluşturur.

Daha sonra, 'ggplot2' paketini kullanarak 'Age_kok_merk' değişkenini 'CreditScore_log' değişkenine karşı görselleştirir. 'stat_smooth' fonksiyonu kullanılarak, veriye uyan doğrusal, ikinci dereceden ve üçüncü dereceden eğriler çizilir. 'geom_point' fonksiyonu ise nokta verilerini grafiğe ekler.

Noktaların her yere saçılması, 'Age_kok_merk' değişkeninin 'CreditScore_log' değişkeniyle düşük bir korelasyona sahip olduğunu veya bu iki değişken arasında sistematik bir ilişkinin olmadığını gösterebilir. Bu durumda, iki değişken arasında doğrusal bir ilişki veya bir model kurmak zor olabilir.

Eğrilerin birbirine çok yakın olması ise, farklı derecelerdeki polinomların verilere benzer şekilde uyması anlamına gelir. Bu da, verilerin karmaşık bir yapıya veya doğrusal olmayan bir ilişkiye sahip olabileceğini düşündürebilir.

```
library(ggplot2)

ggplot(train, aes(x = Age_kok_merk, y = CreditScore_log)) +
  stat_smooth(method = "lm", se = FALSE, color = "green", formula = y ~ x) +
  stat_smooth(method = "lm", se = FALSE, color = "blue", formula = y ~ x + I(x ^ 2)) +
  stat_smooth(method = "lm", se = FALSE, color = "red", formula = y ~ x + I(x ^ 2) + I(x ^ 3)) +
  geom_point(colour = "black", size = 1)
```

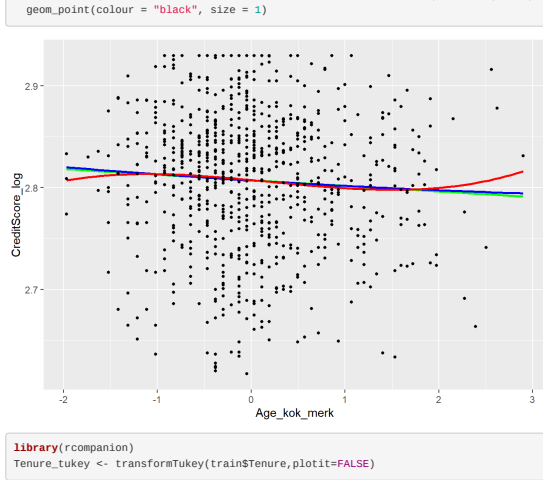

####Tukey's Ladder

```
library(rcompanion)
Tenure_tukey <- transformTukey(train$Tenure,plotit=FALSE)
```

```
##
##     lambda      W Shapiro.p.value
## 435   0.85 0.9447       1.028e-16
##
## if (lambda >  0){TRANS = x ^ lambda}
## if (lambda == 0){TRANS = log(x)}
## if (lambda <  0){TRANS = -1 * x ^ lambda}
```

```
Age_tukey <- transformTukey(train$Age, plotit=FALSE)
```

```
##
##     lambda      W Shapiro.p.value
## 390 -0.275 0.9951         0.01143
##
## if (lambda >  0){TRANS = x ^ lambda}
## if (lambda == 0){TRANS = log(x)}
## if (lambda <  0){TRANS = -1 * x ^ lambda}
```

'Tenure' dönüşümü için elde edilen Lambda değeri -0.275'tir. Negatif bir değer olduğu için, dönüşümün tersine çevrildiğini veya yansıtıldığını gösterir. Bu dönüşüm, orijinal 'Tenure' değerlerinin tersine çevrilmiş veya yansıtılmış bir şekilde kullanılmasını gerektirebilir.

'Tenure' dönüşümü için elde edilen W değeri 0.9951'dir. Bu, dönüşümden sonra oluşan veri setinin normal dağılıma oldukça yakın olduğunu gösterir. Veri seti normal dağılıma yakın olduğu için, dönüşümün normalliteye uygun olduğu söylenebilir.

'Age' dönüşümü için elde edilen Lambda değeri 0.01143'tür. Bu, dönüşümün logaritmik bir şekilde gerçekleştiğini gösterir. Orijinal 'Age' değerlerinin logaritması kullanılarak dönüşüm yapılması gerekebilir.

'Age' dönüşümü için elde edilen W değeri 0.9951'dir. Bu, dönüşümden sonra oluşan veri setinin normal dağılıma oldukça yakın olduğunu gösterir.

```
library(caret)
```

```
## Zorunlu paket yükleniyor: lattice
```

```
featurePlot(x = train[, c("Age", "Tenure", "EstimatedSalary")], y = train$CreditScore) # Saçılım grafiği
```

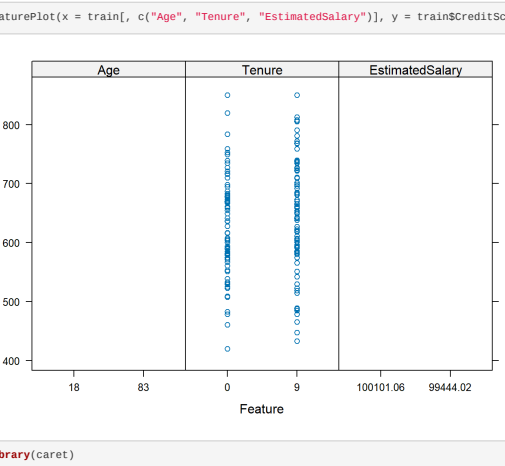

#Sacılım cizimi

```
library(caret)
featurePlot(x=train[,c("Age","Tenure")],y=train$NumOfProducts)
```

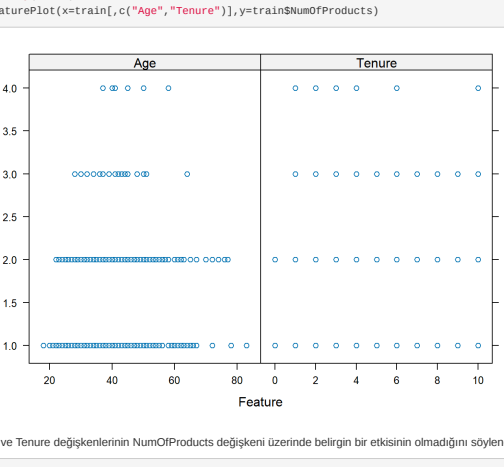

Age ve Tenure değişkenlerinin NumOfProducts değişkeni üzerinde belirgin bir etkisinin olmadığını söylenebilir.

```
train$Tenure_log<-log(train$Tenure) #FEV'de logaritmik dönüşüm
train$Age_kok<-sqrt(train$Age) #Age'de kök dönüşümü
```

```
library(ggplot2)

ggplot(train, aes(NumOfProducts, Tenure, label = rownames(train))) +
  geom_point(size = 0.70) +
  geom_text(label = rownames(train), nudge_x = 0.20, check_overlap = TRUE, size = 2.5) +
  geom_smooth(method = "loess", col = "red", se = FALSE)
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning in simpleLoess(y, x, w, span, degree = degree, parametric = parametric,
## : pseudoinverse used at 0.985
```

```
## Warning in simpleLoess(y, x, w, span, degree = degree, parametric = parametric,
## : neighborhood radius 1.015
```

```
## Warning in simpleLoess(y, x, w, span, degree = degree, parametric = parametric,
## : reciprocal condition number 4.6074e-30
```

```
## Warning in simpleLoess(y, x, w, span, degree = degree, parametric = parametric,
## : There are other near singularities as well. 1
```

```
## Warning: The following aesthetics were dropped during statistical transformation: label
## ℹ This can happen when ggplot fails to infer the correct grouping structure in
##   the data.
## ℹ Did you forget to specify a `group` aesthetic or to convert a numerical
##   variable into a factor?
```

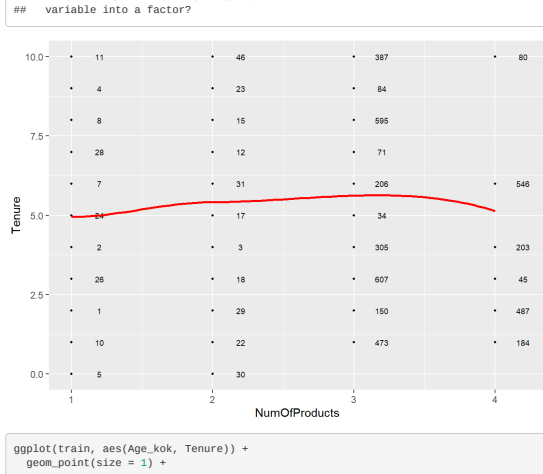

```
ggplot(train, aes(Age_kok, Tenure))+
  geom_point(size = 1) +
  geom_text(label = rownames(train), nudge_x = 0.04, check_overlap = TRUE, size = 2.5) +
  geom_smooth(method = "loess", col = "darkblue", se = FALSE)
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

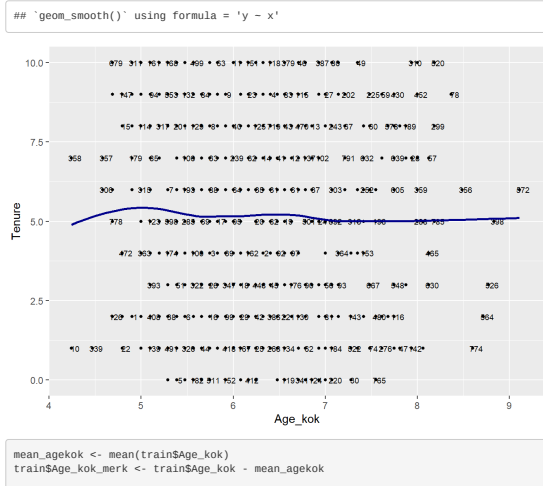

```
mean_agekok <- mean(train$Age_kok)
train$Age_kok_merk <- train$Age_kok - mean_agekok

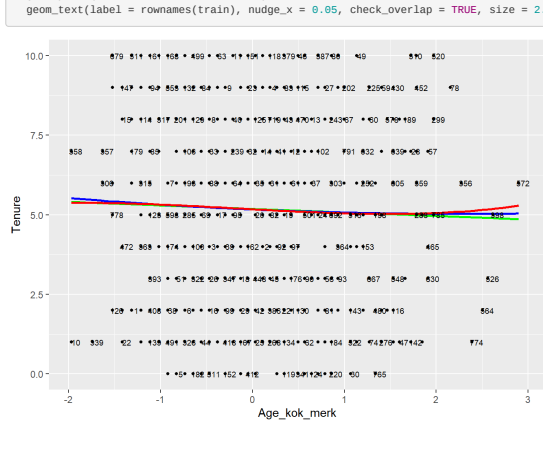ggplot(train, aes(x = Age_kok_merk, y = Tenure)) +
  stat_smooth(method = "lm", se = FALSE, color = "green", formula = y ~ x) +
  stat_smooth(method = "lm", se = FALSE, color = "blue", formula = y ~ x + I(x ^ 2)) +
  stat_smooth(method = "lm", se = FALSE, color = "red", formula = y ~ x + I(x ^ 2) + I(x ^ 3)) +
  geom_point(colour = "black", size = 1) +
  geom_text(label = rownames(train), nudge_x = 0.05, check_overlap = TRUE, size = 2.5)
```