

Veri olarak "dataset2" veri setini seçtim. Veri analizime başlamadan önce seçtiğim sütunlar "Glucose", "DiabetesPedigreeFunction", "Age" ve "Outcome". Bu veri setinde verilen bilgiler doğrultusunda hastalık var mı yok mu ona bakacağım.

Kayıp Gözlem Var mı?

```
#kayıp gözlem
missing_data <- colSums(is.na(dataset2))
empty_data <- colSums(dataset2 == "")

print(missing_data)
print(empty_data)

> print(missing_data)
      Glucose DiabetesPedigreeFunction      Age
           0                0           0
      Outcome
           0

> print(empty_data)
      Glucose DiabetesPedigreeFunction      Age
           0                0           0
      Outcome
           0

> |
```

Seçmiş olduğum veri seti için önce boş gözlem olup olmadığını kontrol ettim. Sonuç olarak boş gözlem olmadığı görülmektedir.

Normallik Testi

```
#normallik testi
#verimin normal olup olmadığına bakıyorum
#H0:veri normal dağılıma sahiptir.
#H1:veri normal dağılıma sahip değildir.
#Shapiro-Wilk Test for normality
shapiro.test(dataset2$Glucose)
shapiro.test(dataset2$DiabetesPedigreeFunction)
shapiro.test(dataset2$Age)
> shapiro.test(dataset2$Glucose)

      Shapiro-Wilk normality test

data:  dataset2$Glucose
W = 0.97171, p-value = 5.121e-11

> shapiro.test(dataset2$DiabetesPedigreeFunction)

      Shapiro-Wilk normality test

data:  dataset2$DiabetesPedigreeFunction
W = 0.26331, p-value < 2.2e-16

> shapiro.test(dataset2$Age)

      Shapiro-Wilk normality test

data:  dataset2$Age
W = 0.87463, p-value < 2.2e-16
```

3 değişkenimde p değerinin çok düşük olmasından kaynaklı normal dağılıma sahip olmadıkları yorumu yapılabilir.

Korelasyon

```
#korelasyon
```

```
cor_matrix <- cor(dataset2, use = "complete.obs")  
print(cor_matrix)
```

```
ggpairs(dataset2, title = "Korelasyon Matriksi")
```

```
> print(cor_matrix)
```

	Glucose	DiabetesPedigreeFunction	Age	Outcome
Glucose	1.0000000	0.12329729	0.26515351	0.4794950
DiabetesPedigreeFunction	0.1232973	1.00000000	0.03122435	0.1124891
Age	0.2651535	0.03122435	1.00000000	0.2373498
Outcome	0.4794950	0.11248909	0.23734982	1.0000000


```
> |
```

Glucose-outcome arasındaki ilişki: orta ilişki

Dpf-outcome arasındaki ilişki : zayıf ilişki

Age-outcome arasındaki ilişki: düşük ilişki

Korelasyon Matriksi



Karar Ağacı Modeli


Karar ağacı için “outcome” sütununu seçip model oluşturmaya çalışıyorum.

```
# Karar ağacı modelinin kurulması
```

```
tree_model <- rpart(Outcome ~ ., data = dataset2, method = "class")
```

```
summary(tree_model)
```

```
rpart.plot(tree_model, type = 3, extra = 101, fallen.leaves = TRUE)
```



Naive Bayes Modeli

```
#Naive-Bayes ile model oluşturma

if (!require(e1071)) install.packages("e1071")
if (!require(dplyr)) install.packages("dplyr")
if (!require(caret)) install.packages("caret")

library(e1071)
library(dplyr)
library(caret)

str(dataset2)

# Veriyi eğitim ve test setlerine ayırma
set.seed(123)
train_index <- createDataPartition(dataset2$Outcome, p = 0.7, list = FALSE)
train_data <- dataset2[train_index, ]
test_data <- dataset2[-train_index, ]
# Naive Bayes modelinin kurulması
nb_model <- naiveBayes(Outcome ~ ., data = train_data)

# Model özetinin incelenmesi
print(nb_model)
```

Naive Bayes Classifier for Discrete Predictors

Call:

naiveBayes.default(x = X, y = Y, laplace = laplace)

A-priori probabilities:

Y	0	1
	0.6536313	0.3463687

Conditional probabilities:

	Glucose	
Y	[,1]	[,2]
0	111.641	26.31288
1	143.043	29.54974

	DiabetesPedigreeFunction	
Y	[,1]	[,2]
0	52.96069	267.6221
1	122.80949	384.3710

	Age	
Y	[,1]	[,2]
0	31.48148	11.60291
1	37.58065	11.49460

Bu çıktıları göre;

Sınıf 0 (diyabet olmayan) olasılığı %65.36, sınıf 1 (diyabet olan) olasılığı %34.64'tür.

Diyabetik bireyler daha yüksek kan şekeri seviyelerine ve diyabet soy geçmişi fonksiyon değerlerine sahiptir.

Diyabetik bireylerin yaş ortalaması biraz daha yüksektir.

Yorumları yapılabilir.